

# Proyecto 1

Análisis DataSet FIFA WORLD CUP

Estudiante: Enzo Vásquez Cornejo  
Profesor: Felipe Gómez M.  
Repositorio: [Click Aquí](#)

Fecha de entrega: 5 de julio de 2026  
Rancagua, Chile

# Índice de Contenidos

|                                              |           |
|----------------------------------------------|-----------|
| <b>1. Descripción del Proyecto</b>           | <b>1</b>  |
| <b>2. Estructura del repositorio</b>         | <b>2</b>  |
| <b>3. Evolución del Desarrollo</b>           | <b>3</b>  |
| <b>4. Análisis uso de Git</b>                | <b>3</b>  |
| 4.1. Historial . . . . .                     | 3         |
| 4.2. Integración de cambios . . . . .        | 6         |
| 4.3. Visualización del Repositorio . . . . . | 9         |
| 4.4. Métricas . . . . .                      | 9         |
| <b>5. Reflexión Final</b>                    | <b>10</b> |

# Índice de Figuras

|                                        |   |
|----------------------------------------|---|
| 1. Ejemplos plots. . . . .             | 1 |
| 2. Total commits. . . . .              | 3 |
| 3. Días de Actividad. . . . .          | 4 |
| 4. Archivos más modificados. . . . .   | 4 |
| 5. Ramas del repositorio. . . . .      | 4 |
| 6. Merges Realizados. . . . .          | 5 |
| 7. Historial de ramas. . . . .         | 6 |
| 8. Conflicto realizado . . . . .       | 7 |
| 9. Conflicto solucionado. . . . .      | 8 |
| 10. Visualización repositorio. . . . . | 9 |

# Índice de Códigos

|                               |   |
|-------------------------------|---|
| 1. Tree Repositorio . . . . . | 2 |
|-------------------------------|---|

# 1. Descripción del Proyecto

El proyecto consiste en un análisis exploratorio y modelado predictivo sobre datos históricos de la Copa del Mundo FIFA (1930–2018), utilizando R como lenguaje principal. Se emplean dos datasets obtenidos de TidyTuesday: `worldcups.csv` (21 torneos) y `wcmatches.csv` (900 partidos). El objetivo principal es predecir el resultado de un partido (`outcome`: H/A/D) mediante regresión logística multinomial, comparando tres enfoques: StepAIC, Ridge y Lasso.

En cada archivo `.R` se hacen distintas tareas. Por una parte, en `load`, nos encargamos de cargar los datasets y ver que variables posee. En `clean`, limpiamos los datasets (por ej. borrar NA en variables críticas). En `eda` generamos plots con el fin de conocer nuestros datasets y poder hacer un modelo. Algunos plots que se crearon:

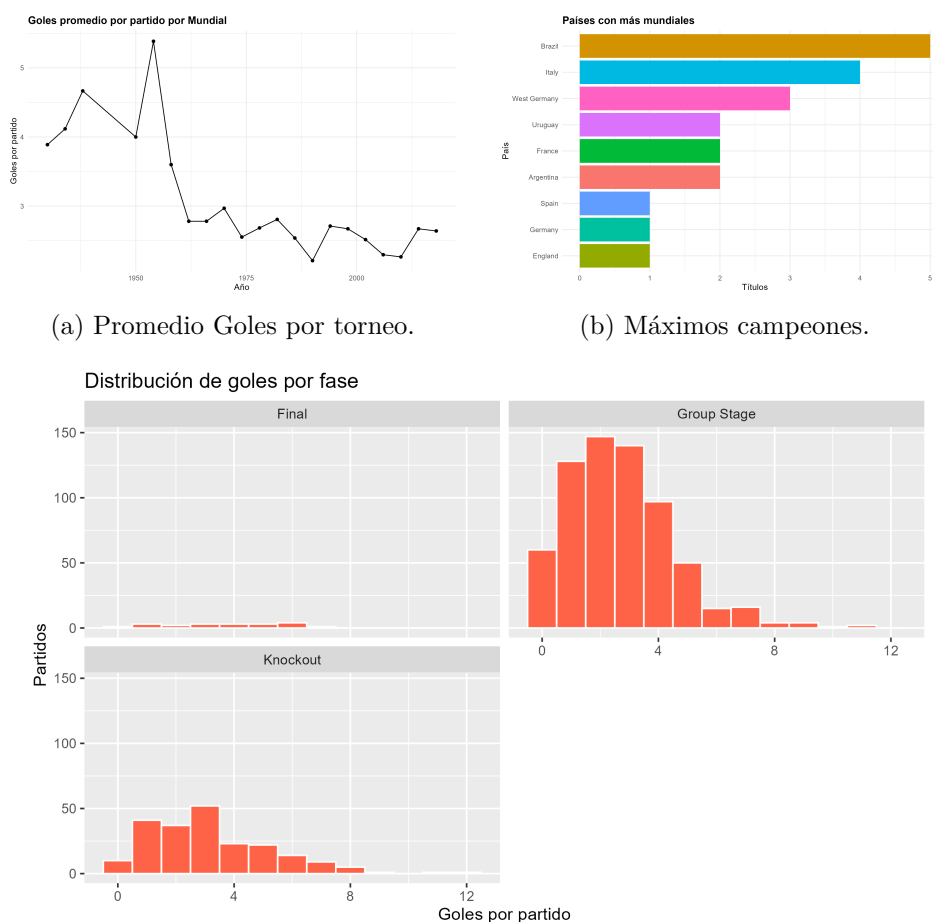


Figura 1: Ejemplos plots.

Finalmente, en modeling se creó un modelo predictivo de quien ganaría un partido. Se buscó el mejor modelo usando stepAIC, Ridge y LASSO, siendo este primero con un mayor accuracy.

## 2. Estructura del repositorio

A continuación, un esquema de la estructura del repositorio:

Código 1: Tree Repositorio

```
1 fifa-worldcup-analysis/  
2   R/  
3   |--load.R  
4   |--clean.R  
5   |--eda.R  
6   |--modeling.R  
7   |--utils.R  
8   data/  
9   |--raw/  
10  |--processed/  
11  output/plots/  
12  report/  
13  Makefile  
14  README.md  
15  .gitignore
```

- Scripts (R/): pipeline secuencial no numerado. Cada script tiene una responsabilidad única: carga, limpieza, EDA y modelado. utils.R tiene funciones reutilizadas por eda.R y modeling.R.
- Datos (data/): separación entre crudos (raw/) y procesados (processed/). Los CSVs originales se trackean por ser livianos; los .rds son outputs intermedios generados por clean.R.
- Outputs (output/plots/): ignorados en .gitignore, son archivos derivados del código ya trackeado (son por ej. los .png de los gráficos).
- Makefile: para facilitar la ejecución. Tiene distintos targets, como load, clean, eda, modeling, report, all. Se recomienda usar este último para un buen flujo.


### 3. Evolución del Desarrollo

- **24-26 jun:** Inicialización del repositorio, estructura de carpetas, carga y limpieza de datos (`load.R`, `clean.R`). Cada archivo con una rama.
- **29 jun:** Rama `eda-rama`: análisis exploratorio, visualizaciones con `ggplot2`. Se trabajó además con `clean.R` en la rama mencionada en este punto.
- **2 jul:** Se agregaron más plots y se volvió a ajustar `clean`.
- **3-4 jul:** Rama `model-rama`: modelado multinomial, StepAIC, Ridge y Lasso con `glmnet`. Se ajustó `utils.R` para reutilizar funciones.
- **4-5 jul:** Merge de `eda-rama` en `model-rama`, generación y resolución manual de conflicto en `README.md`. Además se hizo la integración final en `main`, `Makefile`, informe y documentación.

En total se trabajaron 8 días.

### 4. Análisis uso de Git

#### 4.1. Historial



```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git log --oneline | wc -l
32

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git rev-list --count HEAD
32

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$
```

Figura 2: Total commits.

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git log --pretty=format:"%h | %ad | %an | %s" --date=short
695c3e0 | 2026-07-05 | Enzo Vásquez | fix ultima linea
a5ad14f | 2026-07-05 | enzo | merge con rama model
98af904 | 2026-07-05 | enzo | se agrega carpeta de reporte
46cdf1f | 2026-07-05 | enzo | actualizacion de Rproj (tipo de ejecucion)+}
8e97d40 | 2026-07-05 | enzo | Se actualiza el readme
4f59e56 | 2026-07-05 | enzo | Merge branch 'main' of https://github.com/enzo-compiled/analysis_fifa_wc
57c3d63 | 2026-07-05 | Enzo Vásquez | Revise README for FIFA World Cup analysis project
95775b7 | 2026-07-05 | enzo | plots
615cdce | 2026-07-05 | enzo | se añade formato de reporte
ef7c205 | 2026-07-05 | enzo | se añade makefile para ejecución
28f51a2 | 2026-07-05 | enzo | se añade archivos que no se deben trackear de report
b71e2b4 | 2026-07-05 | enzo | elimino trackeo de plots (png)
106fc5a | 2026-07-04 | enzo | actualización plots
0cfcf5b | 2026-07-04 | enzo | Se agrega función/es para el acc de utils
a145731 | 2026-07-04 | enzo | Se agrega función de utils para tema de plots
b6af291 | 2026-07-04 | enzo | Se agrega utils que contiene funciones reutilizables en el proyecto
a3c7060 | 2026-07-03 | enzo | agrego borrador modelo
c6d0652 | 2026-07-02 | enzo | Se agregan más plots
7c6ec40 | 2026-07-02 | enzo | Se agregan nuevos plots
76eb043 | 2026-07-02 | enzo | wcmatches procesado}
d77e832 | 2026-07-02 | enzo | se agrega plot de paises con más victorias en partidos
554f9e1 | 2026-07-02 | enzo | Se agregan campos a wcmatches para simplificar eda
eae96ef | 2026-06-29 | enzo | plot 1
d5f5e1f | 2026-06-29 | enzo | Se crea archivo para explorar los df junto a un plot simple
584de54 | 2026-06-29 | enzo | directorio donde se guardan df limpios
ce2f561 | 2026-06-29 | enzo | se agrega función para guardar los df limpios y usar en otros archivos
2f77c0c | 2026-06-26 | enzo | Se crea archivop clean que limpia/agrega campos para ambos dataframes
e5e1e24 | 2026-06-25 | enzo | Se añade archivo de carga de dataframes
37d9b26 | 2026-06-24 | enzo | Se añaden los dataset a utilizar
f48e677 | 2026-06-24 | enzo | Agrega README inicial
5ca3222 | 2026-06-24 | enzo | Agrego archivo gitignore
6881537 | 2026-06-24 | enzo | Levantamiento proyecto en R studio
```

Figura 3: Días de Actividad.

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git log --name-only --pretty=format: | grep -v 'AS' | sort | uniq -c | sort -nr
31
5 R/eda.R
4 README.md
3 output/plots/top_winners_games.png
3 output/plots/top_winners_final.png
3 output/plots/top_rivales.png
3 output/plots/goles_por_fase.png
3 output/plots/goals_per_game.png
3 output/plots/asistencia_goles.png
3 R/clean.R
3 .gitignore
2 fifa_wc.Rproj
2 data/processed/wcmatches.rds
2 R/modeling.R
1 report/mini-proyecto.pdf
1 report/mini-proyecto.html
1 report/mini-proyecto.Rmd
1 data/raw/worldcups.csv
1 data/raw/wcmatches.csv
1 data/processed/worldcups.rds
1 R/utils.R
1 R/load.R
1 Makefile
```

Figura 4: Archivos más modificados.

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git branch
clean-rama
eda-rama
load-rama
* main
model-rama
```

Figura 5: Ramas del repositorio.

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git merge clean-rama
Updating 37d9b26..2f77c0c
Fast-forward
 R/clean.R | 19 ++++++
 R/load.R  | 12 ++++++
 2 files changed, 31 insertions(+)
 create mode 100644 R/clean.R
 create mode 100644 R/load.R
```

(a) Merge entre clean-main.

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git merge model-rama
Auto-merging README.md
CONFLICT (content): Merge conflict in README.md
Automatic merge failed; fix conflicts and then commit the result.

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main|MERGING)
$
```

(b) Three-way merge model-main

Figura 6: Merges Realizados.

Se creó un conflicto en el archivo `README.md` durante el three way merge. Se explicará con más detalle la resolución de este en la siguiente sección.

Pd. se puede usar `git log --merges --oneline` para ver los merges realizados.

## 4.2. Integración de cambios

```
Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git log --oneline --graph --all --decorate
* 695c3e0 (HEAD -> main, origin/main, origin/HEAD) fix ultima linea
* a5ad14f merge con rama model
|
| * 46cdf1f (model-rama) actualizacion de Rproj (tipo de ejecucion)+}
| * 8e97d40 Se actualiza el readme
| * 95775b7 (origin/model-rama) plots
| * 615cdce se añade formato de reporte
| * ef7c205 se añade makefile para ejecución
| * 28f51a2 se añade archivos que no se deben trackear de report
| * b71e2b4 elimino trackeo de plots (png)
| * 106fc5a actualización plots
| * 0cfcf5b Se agrega función/es para el acc de utils
| * a145731 Se agrega función de utils para tema de plots
| * b6af291 Se agrega utils que contiene funciones reutilizables en el proyecto
| * a3c7060 agrego borrador modelo
| * c6d0652 (origin/eda-rama, eda-rama) Se agregan más plots
| * 7c6ec40 Se agregan nuevos plots
| * 76eb043 wcmatches procesado}
| * d77e832 se agrega plot de países con más victorias en partidos
| * 554f9e1 Se agregan campos a wcmatches para simplificar eda
| * eae96ef plot 1
| * d5f5e1f Se crea archivo para explorar los df junto a un plot simple
| * 584de54 directorio donde se guardan df limpios
| * ce2f561 Se agrega función para guardar los df limpios y usar en otros archivos
| * 98af904 se agrega carpeta de reporte
| * 4f59e56 Merge branch 'main' of https://github.com/enzo-compiled/analysis_fifa_wc
|/
|
| * 57c3d63 Revise README for FIFA World Cup analysis project
| * 2f77c0c (origin/clean-rama, clean-rama) Se crea archivop clean que limpia/agrega campos para ambos dataframes
| * e5e1e24 (origin/load-rama, load-rama) Se añade archivo de carga de dataframes
|/
* 37d9b26 Se añaden los dataset a utilizar
* f48e677 Agrega README inicial
* 5ca3222 Agrego archivo gitignore
* 6881537 Levantamiento proyecto en R studio
```

Figura 7: Historial de ramas.

Cómo se vió en la sección anterior se crearon 5 ramas.

- Main: La rama principal que lleva el proyecto funcional.
- Load: Rama encargada de manejar el archivo load.R. Cualquier cambio que haga en este archivo, mejor hacerlo en esta rama y después hacer el merge en main (es lo mismo para todas las otras ramas).
- Clean: Encargada del archivo clean.R
- Eda: Encargada del archivo eda.R
- Model: Se encarga principalmente del modelo predictivo, pero para no hacer más ramas se aprovechó de crear el Makefile, el archivo de reporte .Rmd y una archivo de funciones utils.R



Ahora veamos con más detalle el conflicto:

```
Enzo Vázquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)
$ git merge model-rama
Auto-merging README.md
CONFLICT (content): Merge conflict in README.md
Automatic merge failed; fix conflicts and then commit the result.

Enzo Vázquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)MERGING
$ git status
On branch main
Your branch is ahead of 'origin/main' by 4 commits.
(use "git push" to publish your local commits)

You have unmerged paths.
  (fix conflicts and run "git commit")
  (use "git merge --abort" to abort the merge)

Changes to be committed:
  modified:   .gitignore
  new file:   Makefile
  modified:   R/clean.R
  new file:   R/eda.R
  new file:   R/modeling.R
  new file:   R/utlis.R
  new file:   data/processed/wcmatches.rds
  new file:   data/processed/worldcups.rds
  modified:   fifa_wc.Rproj
  new file:   output/plots/asistencia_goles.png
  new file:   output/plots/goles_por_game.png
  new file:   output/plots/goles_por_fase.png
  new file:   output/plots/top_rivales.png
  new file:   output/plots/top_winners_final.png
  new file:   output/plots/top_winners_games.png
  new file:   report/mini-proyecto.Rmd

Unmerged paths:
  (use "git add <file>..." to mark resolution)
  both modified:   README.md

Enzo Vázquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main)MERGING
$ |
```

(a) Git status luego del merge.

```
##### HEAD
# FIFA World Cup Analysis (1930-2018)
Análisis exploratorio y modelado predictivo sobre datos históricos de la Copa del Mundo FIFA.

## Dataset
- **Fuente:** [FIFA World Cup, Kaggle] (https://www.kaggle.com/datasets/evangower/fifa-world-cup)
- Archivos: 'worldcups.csv', 'wcmatches.csv'.

## Requisitos
- R (>= 4.1.0)
- Paquetes: 'tidyverse', 'nnet', 'MASS', 'glmnet', 'caret'
...
install.packages(c("tidyverse", "nnet", "MASS", "glmnet", "caret"))

## Estructura del proyecto
$ bash
FifaWorldCup-analysis/
├── R/
│   ├── load.R
│   ├── clean.R
│   ├── eda.R
│   ├── modeling.R
│   └── utlis.R
├── data/
│   ├── raw/
│   ├── processed/
│   ├── output/plots/
│   ├── report/
│   ├── Makefile
│   ├── README.md
│   └── .gitignore
```

(b) README con conflicto 1

```
## Uso

### Linux/Mac
$ bash
make all
...

### Windows
$ bash
#Instalar make con chocolatey (una vez)
choco install make

make all
...

## Targets disponibles
| Target | Descripción |
|-----|-----|
| 'make all' | Ejecuta pipeline completo |
| 'make load' | Carga datos |
| 'make clean' | Limpieza |
| 'make eda' | Análisis exploratorio |
| 'make model' | Modelado |
| 'make report' | Renderiza informe |

El reporte es almacenado en el directorio 'reporte' con formato html.

## Análisis del dataset FIFA WC (1930-2018).
---
La idea del proyecto es explorar el dataset FIFA WC. Para ello, se hizo una carga de los datasets, una limpieza, un eda y finalmente se entrenó un modelo logístico multinomial 70/30, con el fin de predecir el ganador de un partido a partir de una variable categórica 'outcome (H/A/D)'.

>>>>> model-rama
```

(c) README con conflicto 2

Figura 8: Conflicto realizado

El conflicto se generó intencionalmente editando `README.md` en paralelo desde dos ramas distintas. La resolución consistió en editar `README.md` dejando la versión de la rama `main`. Se borraron los símbolos dentro del archivo y solo se dejó la versión final.

```
Unmerged paths:
(use "git add <file>..." to mark resolution)
    both modified:   README.md

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main|MERGING)
$ git add README.md

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main|MERGING)
$ git status
On branch main
Your branch is ahead of 'origin/main' by 4 commits.
  (use "git push" to publish your local commits)


All conflicts fixed but you are still merging.
  (use "git commit" to conclude merge)

Changes to be committed:
  modified:   .gitignore
  new file:   Makefile
  modified:   R/clean.R
  new file:   R/eda.R
  new file:   R/modeling.R
  new file:   R/utis.R
  modified:   README.md
  new file:   data/processed/wcmatches.rds
  new file:   data/processed/worldcups.rds
  modified:   fifa_wc.Rproj
  new file:   output/plots/asistencia_goles.png
  new file:   output/plots/goals_per_game.png
  new file:   output/plots/goles_por_fase.png
  new file:   output/plots/top_rivales.png
  new file:   output/plots/top_winners_final.png
  new file:   output/plots/top_winners_games.png
  new file:   report/mini-proyecto.Rmd

Enzo Vásquez@LAPTOP-CBBRPSGL MINGW64 ~/Desktop/fifa_wc (main|MERGING)
$ |
```

Figura 9: Conflicto solucionado.

### 4.3. Visualización del Repositorio



(a) Commits por mes.



(b) Contribuciones al repo.

Figura 10: Visualización repositorio.

### 4.4. Métricas

Respecto a los gráficos del punto anterior. Se hicieron 2065 inserciones de líneas totales y 20 eliminaciones. El periodo con más contribuciones fue a fines del mes pasado (tenía menos carga académica sino mal lo recuerdo). El archivo, cómo se mostró anteriormente, más modificado fue `eda.R` dado que se fue modificando porque casi al final de proyecto se añadió `utils.R` que tiene una función para el tema de plots.

## 5. Reflexión Final

El desarrollo de este proyecto permitió consolidar el uso de Git como herramienta de control de versiones en un flujo de trabajo real. La organización en ramas facilitó el desarrollo paralelo sin afectar la estabilidad de **main**. La generación intencional de un conflicto de merge evidenció cómo Git gestiona divergencias y la importancia de commits atómicos y descriptivos para facilitar su resolución. El historial resultante refleja una evolución progresiva y trazable del proyecto que es mejorable a su debido tiempo.